

Avaliação de Desempenho de Arquitetura de Computadores

- Disciplina:

Avaliação de Desempenho de Sistemas Computacionais

- Tema: Arquitetura de Computadores
- Objetivo da aula:
Apresentar conceitos, métricas, técnicas e tendências para avaliar o desempenho de arquiteturas de computadores, incluindo CPU, memória e sistemas multiprocessados.
- Referência:
GONÇALVES, Marcos José Santana; MACAMBIRA, Juarez. Avaliação de Desempenho de Sistemas Computacionais. Fortaleza: EdUECE, 2017.
- **Referência do Livro:**
Cap. 1, Cap. 5, Cap. 12 e Cap. 31 – Avaliação de desempenho em arquiteturas

Importância da Avaliação em Arquitetura de Computadores

- Arquitetura de computadores define **como o hardware executa instruções e gerencia recursos**.
- O desempenho impacta diretamente em:
 - Tempo de resposta** de aplicações.
 - Eficiência energética** e custo operacional.
 - Escalabilidade** de sistemas multiprocessados.
- Avaliar arquiteturas permite:
 - Comparar diferentes **CPUs, memórias e barramentos**.
 - Identificar gargalos em **pipeline, cache e E/S**.
 - Orientar escolhas tecnológicas em projetos de sistemas.

Métricas Fundamentais de Desempenho em Arquitetura

- **Tempo de execução (Execution Time):** tempo total para concluir um programa.
- **CPI (Ciclos por Instrução):** média de ciclos de clock gastos por instrução.
- **MIPS (Milhões de Instruções por Segundo):** taxa de execução de instruções.
- **MFLOPS (Milhões de Operações de Ponto Flutuante por Segundo):** avalia desempenho em cálculos numéricos.
- **Throughput:** número de tarefas concluídas em um intervalo de tempo.

Fatores que Impactam o Desempenho da CPU

- Frequência de clock: determina a velocidade básica de execução.
- Pipeline: divide a execução em estágios, aumentando o paralelismo.
- Conjunto de instruções (ISA): influencia a complexidade e a eficiência da execução.
- Paralelismo em nível de instrução (ILP): uso de técnicas como superescalar e execução fora de ordem.
- Número de núcleos: multiprocessamento amplia throughput, mas exige sincronização eficiente.

Avaliação de Desempenho em Pipeline de Instruções

- Frequência de clock: determina a velocidade básica de execução.
- Pipeline: divide a execução em estágios, aumentando o paralelismo.
- Conjunto de instruções (ISA): influencia a complexidade e a eficiência da execução.
- Paralelismo em nível de instrução (ILP): uso de técnicas como superescalar e execução fora de ordem.
- Número de núcleos: multiprocessamento amplia throughput, mas exige sincronização eficiente.

Hierarquia de Memória e Impacto no Desempenho

- Hierarquia de memória:

registradores → cache → RAM → disco.

- Princípio da localidade:

- Temporal: dados usados recentemente tendem a ser reutilizados.

- Espacial: dados próximos tendem a ser acessados em sequência.

- Avaliação de desempenho:

- Hit rate da cache.

- Tempo médio de acesso à memória (AMAT).

- Impacto: gargalos de memória podem anular ganhos da CPU, exigindo otimização do uso de cache.

Avaliação de Desempenho em Sistemas de Entrada/Saída (E/S)

- Dispositivos de E/S:
 - discos, SSDs, placas de rede, periféricos.
- Métricas de avaliação:
 - Throughput: taxa de transferência (MB/s).
 - Latência de acesso.
 - IOPS (Input/Output Operations per Second).
- Fatores que impactam:
 - Tipo de dispositivo (HDD vs SSD).
 - Políticas de escalonamento de E/S.
 - Interface utilizada (SATA, NVMe, PCIe).
- Conclusão: gargalos de E/S podem limitar o desempenho global do sistema.

Uso de Teoria de Filas na Avaliação de Arquiteturas

- Modelagem de recursos de hardware como sistemas de filas:

- CPU:

instruções → clientes; ciclos de clock → servidores.

- Memória:

requisições → clientes; controladores → servidores.

- Métricas analisadas:

- Tempo médio de espera.
- Utilização do servidor (CPU/memória).
- Throughput do sistema.

- Benefício:

- prever comportamento sob diferentes cargas de trabalho e dimensionar recursos adequadamente.

Benchmarks para Arquiteturas de Computadores

- **Benchmarks sintéticos:**
 - Avaliam componentes específicos (ex.: memória, CPU).
 - Ex.: Dhrystone, Whetstone.
- **Benchmarks de propósito geral:**
 - Simulam cargas de trabalho completas.
 - Ex.: SPEC CPU (inteiros e ponto flutuante).
- **Benchmarks de alto desempenho:**
 - Avaliam arquiteturas voltadas a cálculos intensivos.
 - Ex.: LINPACK (padrão em supercomputadores – ranking TOP500).
- **Objetivo:** comparar arquiteturas diferentes em cenários padronizados.

Avaliação em Arquiteturas Paralelas e Multicore

- Arquiteturas multicore: múltiplos núcleos em um único processador.
- Métricas de avaliação:
 - Speedup (aceleração obtida com múltiplos núcleos).
 - Escalabilidade (desempenho em função do número de processadores).
 - Eficiência do paralelismo.
- Desafios:
 - Sincronização entre threads/processos.
 - Conflitos de acesso à memória compartilhada.
- Exemplo prático:
- ganhos de desempenho em servidores multicore vs limitações do Amdahl's Law.

Lei de Amdahl e Limitações do Paralelismo

- Lei de Amdahl:

- O ganho de desempenho é limitado pela parte sequencial do programa.

- Fórmula:

$$Speedup = \frac{1}{(1-f) + \frac{f}{p}}$$

Onde:

- f = fração paralelizável.
 - p = número de processadores.

- Implicações:

- Mesmo com muitos processadores, o ganho é limitado.
 - Importância de otimizar a parte sequencial do código.

- Conclusão: fundamental na avaliação de arquiteturas paralelas.

Arquiteturas de Memória Compartilhada vs Distribuída

- Memória Compartilhada (SMP):

- Todos os processadores acessam a mesma memória.
- Fácil programação, mas pode gerar conflitos de acesso.

- Memória Distribuída (MPP):

- Cada processador possui memória local.
- Comunicação feita por mensagens (ex.: MPI).
- Escalabilidade maior, mas programação mais complexa.

- Avaliação de desempenho:

- Mede latência de acesso, throughput e eficiência de comunicação.

Impacto da Virtualização no Desempenho da Arquitetura

- Virtualização: insere uma camada entre hardware e sistema operacional (hypervisor).
- Impactos no desempenho:
 - Aumento da latência de acesso a CPU e memória.
 - Overhead no gerenciamento de dispositivos de E/S.
 - Compartilhamento de recursos entre múltiplas VMs.
- Vantagens:
 - Flexibilidade na alocação de recursos.
 - Consolidação de servidores físicos.
- Avaliação: mede perdas de desempenho em comparação com execução nativa.

Avaliação de Desempenho em GPUs e Processamento Massivo

- GPUs (Graphics Processing Units): otimizadas para processamento paralelo massivo.
 - Métricas de avaliação:
 - GFLOPS (operações de ponto flutuante por segundo).
 - Eficiência no uso de núcleos CUDA/OpenCL.
 - Speedup em relação à CPU.
 - Aplicações típicas:
 - Treinamento de modelos de IA.
 - Simulações científicas.
 - Processamento gráfico intensivo.
 - Desafio: equilibrar custo energético e desempenho obtido..
- Cap. 31 – Tendências em arquiteturas paralelas (GPUs e processamento massivo)

Eficiência Energética na Avaliação de Arquiteturas

- Consumo de energia é fator crítico em arquiteturas modernas.
 - Métricas utilizadas:
 - Performance/Watt → quantidade de operações por unidade de energia.
 - Energia por instrução executada.
 - Desafios:
 - Manter alto desempenho reduzindo consumo.
 - Equilibrar velocidade de clock e dissipação térmica.
 - Aplicações práticas:
 - Data centers (custo operacional).
 - Dispositivos móveis (bateria).
- Cap. 31 – Tendências em arquiteturas paralelas (GPUs e processamento massivo)

Estudo de Caso: Benchmark LINPACK e Supercomputadores

- LINPACK: mede desempenho em operações de ponto flutuante.
- Métrica principal: FLOPS (Floating Point Operations per Second).
- Uso:
 - Base do ranking TOP500 de supercomputadores.
 - Avalia eficiência em cálculos científicos e simulações complexas.
- Exemplo prático:** comparação entre arquiteturas de supercomputadores usando GFLOPS/PFLOPS.
- Conclusão:** essencial para medir o poder computacional bruto de arquiteturas massivamente paralelas.

Desafios na Avaliação de Arquiteturas Modernas

- **Heterogeneidade:** integração de CPUs, GPUs e aceleradores especializados (TPUs, FPGAs).
- **Escalabilidade:** dificuldade em prever desempenho em milhares de núcleos.
- **Consumo energético:** necessidade de balancear alto desempenho com sustentabilidade.
- **Complexidade de memória:** múltiplos níveis de cache e arquiteturas NUMA.
- **Virtualização e Cloud:** sobreposição de camadas dificulta medições precisas.

Boas Práticas na Avaliação de Arquiteturas

- Definir métricas adequadas: CPI, MIPS, throughput, eficiência energética.
- Usar benchmarks padronizados: SPEC, LINPACK, Dhrystone, Whetstone.
- Considerar diferentes cenários: cargas de trabalho reais e simuladas.
- Avaliar componentes isoladamente e em conjunto: CPU, memória, E/S.
- Repetir medições em condições variadas: carga leve, média e pesada.
- Interpretar resultados com criticidade: evitar conclusões baseadas em uma única métrica.

Tendências Futuras em Arquitetura de Computadores

- **Computação em nuvem:** arquiteturas otimizadas para ambientes virtualizados e distribuídos.
- **Edge Computing:** processamento próximo ao usuário, reduzindo latência.
- **Arquiteturas heterogêneas:** integração de CPUs, GPUs, TPUs e FPGAs.
- **Computação quântica:** novos modelos de avaliação de desempenho além de métricas clássicas.
- **Sustentabilidade:** foco em Green Computing → mais performance por watt consumido.

Conclusão e Síntese da Aula

- A avaliação de arquiteturas de computadores é essencial para entender limites e potencial de CPUs, memórias e sistemas multiprocessados.
- **Métricas principais:** tempo de execução, CPI, MIPS, throughput, eficiência energética.
- **Técnicas de avaliação:** medição direta, modelagem (teoria de filas), simulação e benchmarks.
- **Tópicos chave abordados:** pipeline, hierarquia de memória, E/S, multicore, GPUs e virtualização.
- **Tendências futuras:** arquiteturas heterogêneas, cloud, edge e green computing.
- **Síntese:** avaliar arquiteturas significa equilibrar desempenho, custo e sustentabilidade.