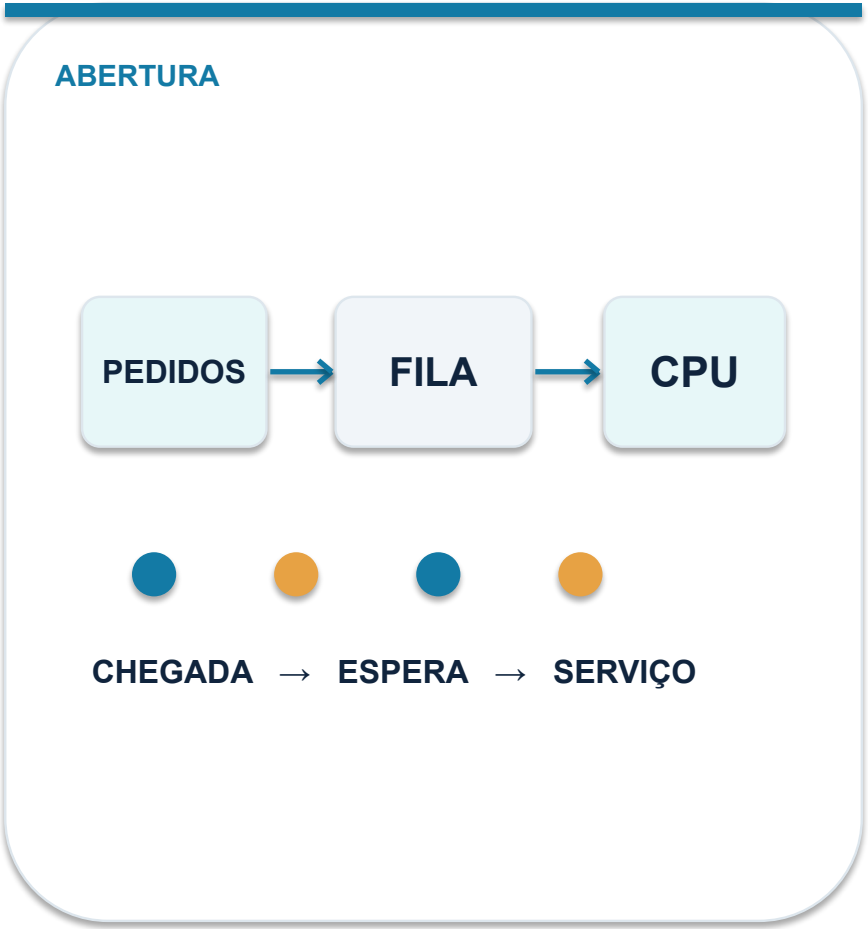
Modelagem matemática e simulação

Um sistema computacional recebe solicitações, consome recursos e produz respostas; seu desempenho depende da relação entre demanda e capacidade.

Nesta aula, construiremos modelos simplificados de filas para compreender utilização, espera, tempo de resposta e possíveis gargalos.

Depois, usaremos simulação de eventos discretos para testar cenários, comparar resultados e discutir limitações dos modelos.

Pergunta inicial: o que acontece quando chegam mais pedidos do que um servidor consegue atender?



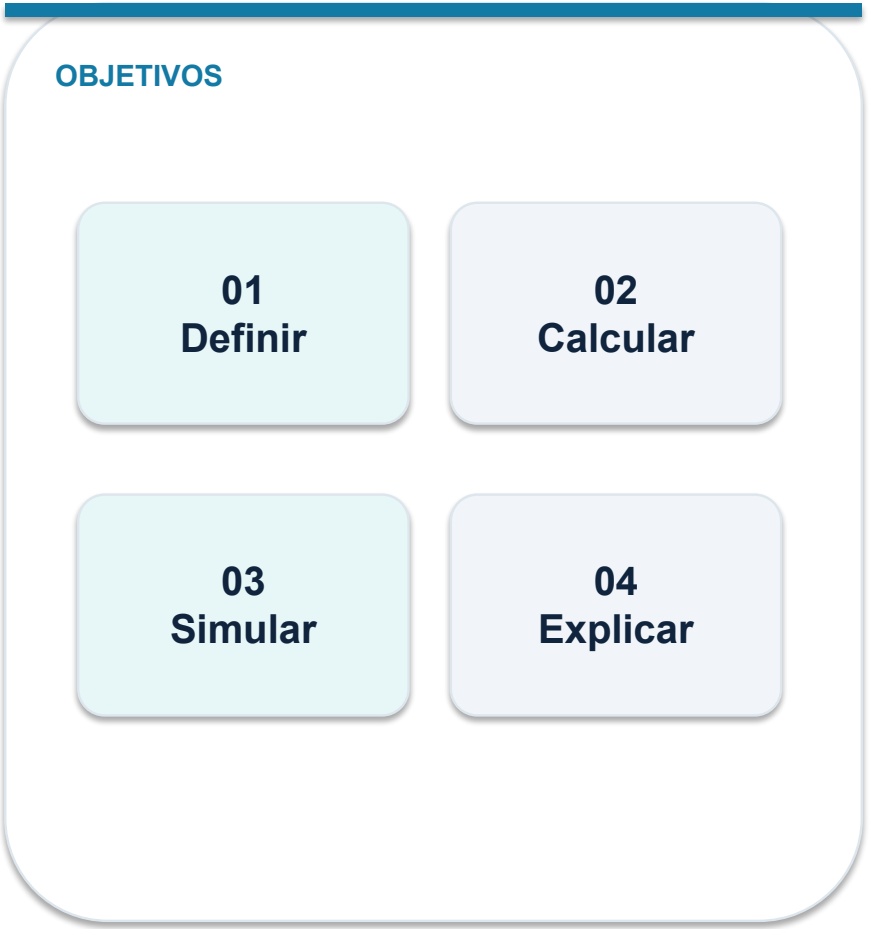
O que você aprenderá

Identificar variáveis de entrada e métricas de saída é o primeiro passo para representar corretamente um serviço computacional.

Você aprenderá a interpretar taxas de chegada e atendimento, utilizar a Lei de Little e reconhecer hipóteses do modelo *M/M/1*.

Ao final, deverá executar uma simulação reprodutível, comparar cenários e justificar conclusões com números e limitações explícitas.

Objetivo prático: transformar uma pergunta sobre desempenho em um pequeno experimento reproduzível.



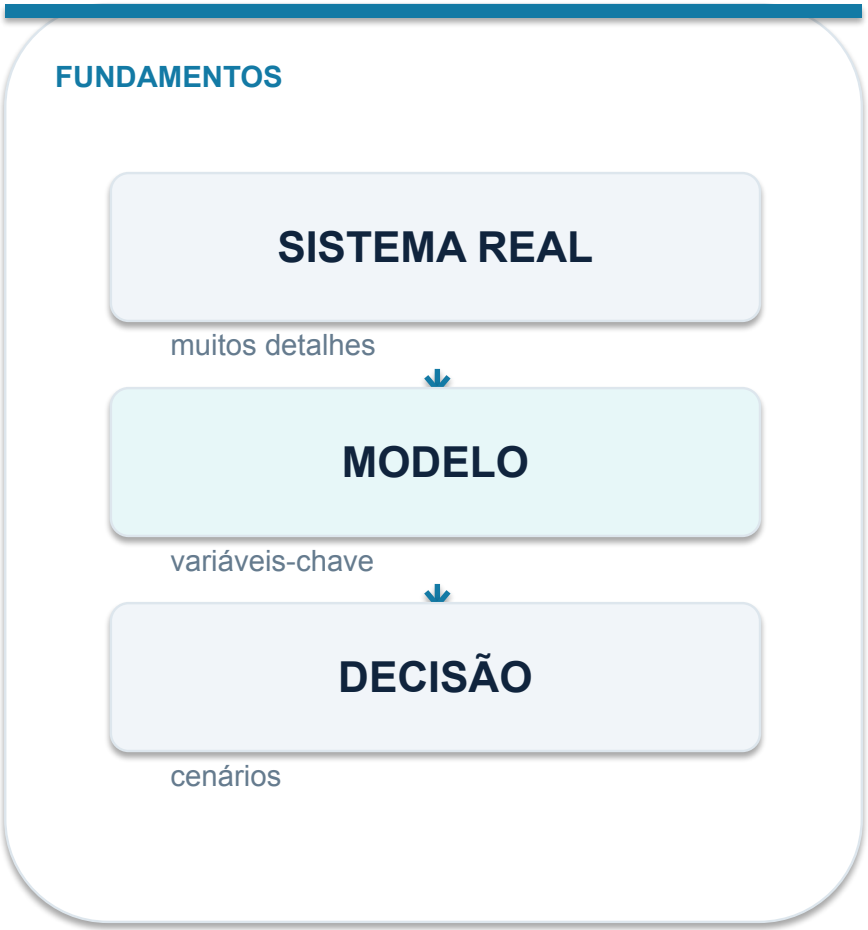
Por que criar um modelo?

Medir um sistema real nem sempre é possível: a aplicação pode não existir, estar em produção ou sofrer restrições operacionais.

Um modelo seleciona características relevantes, como chegadas, capacidade de processamento, disciplina da fila e número de servidores.

Essa abstração permite investigar alternativas com menor custo, desde que as simplificações sejam registradas e posteriormente verificadas.

Abstração significa manter o que importa para a pergunta e omitir detalhes secundários.

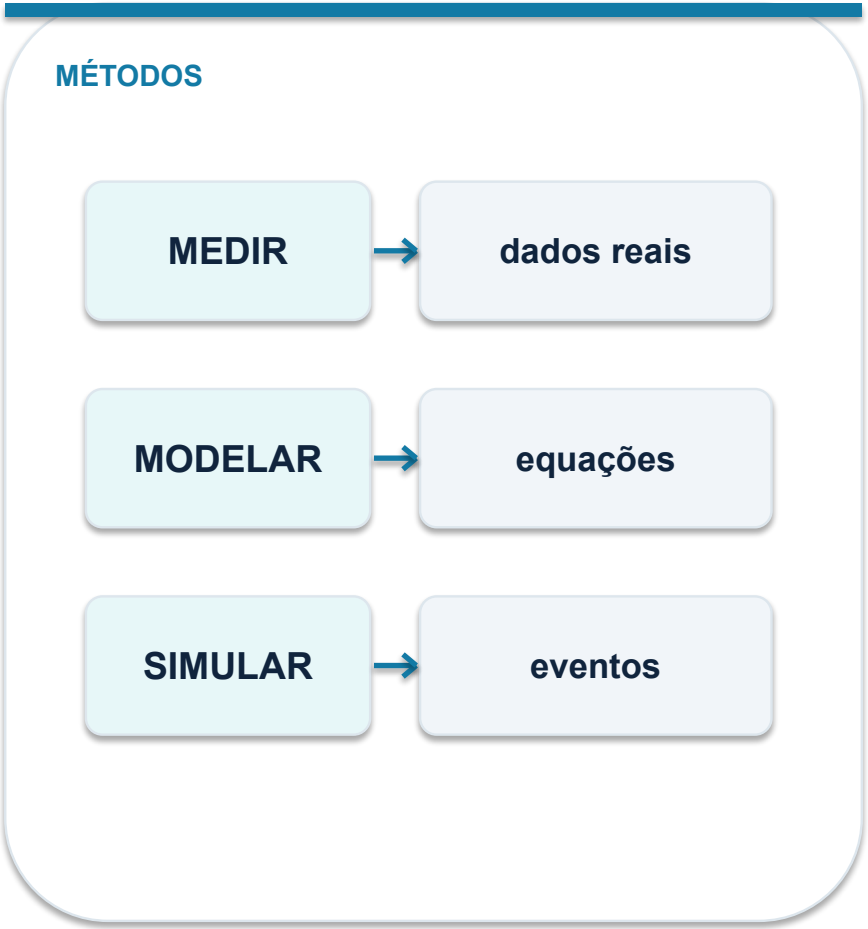


Medição, modelagem e simulação

Medição coleta dados diretamente de um sistema existente, como tempos de resposta registrados em uma aplicação real.

Modelagem matemática usa relações e hipóteses para calcular indicadores; simulação representa a evolução de eventos ao longo do tempo.

Combinar métodos aumenta a confiança: dados reais ajudam a parametrizar modelos, enquanto modelos auxiliam na interpretação dos resultados.



Compare os métodos perguntando: existe sistema pronto, há dados confiáveis e quais cenários precisam ser testados?

Um problema próximo da realidade

Imagine um portal acadêmico que recebe pedidos de matrícula e os envia a um único serviço de processamento.

Em horários comuns chegam poucas solicitações, mas perto do encerramento do prazo a demanda cresce e a fila aumenta.

Queremos estimar quanto tempo os estudantes esperam, quando o servidor se aproxima do limite e quais mudanças podem ajudar.

Pergunta orientadora: a solução é sempre comprar outro servidor ou podemos alterar a carga?

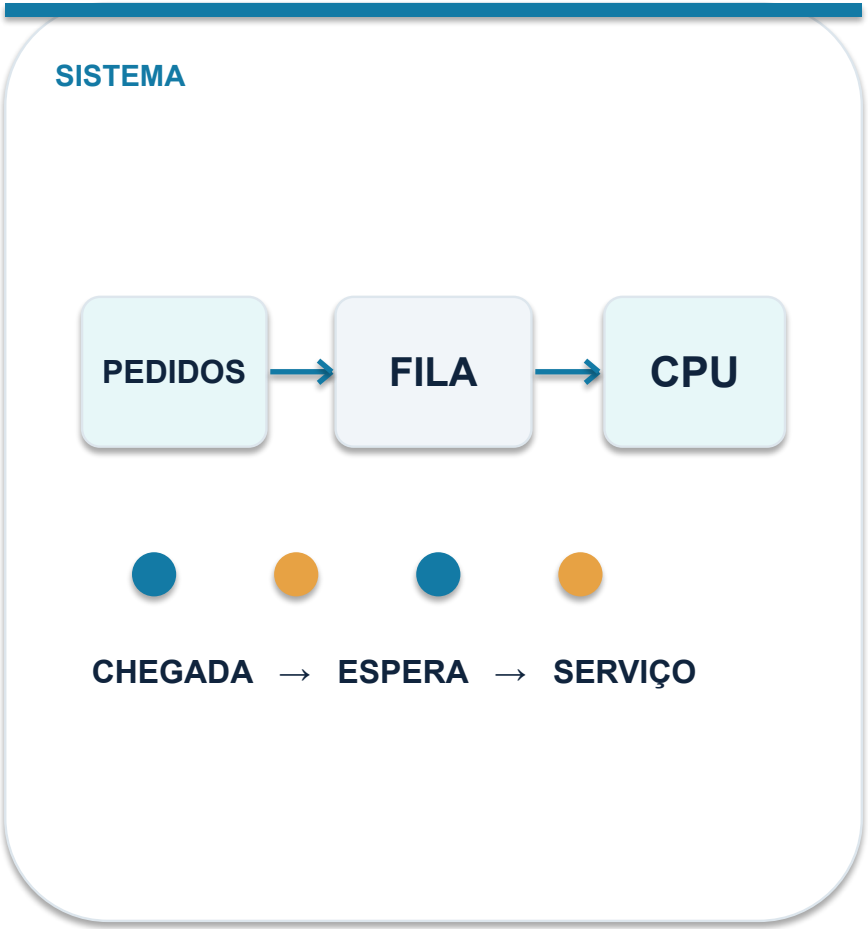


Representando uma fila

Uma fila de atendimento possui uma fonte de solicitações, uma área de espera e um ou mais recursos de serviço.

Quando o servidor está livre, a solicitação inicia o processamento; caso contrário, aguarda conforme uma regra de atendimento.

No exemplo adotaremos ordem de chegada, um servidor e espaço ilimitado de espera, reconhecendo que sistemas reais podem impor limites.



A regra primeiro a chegar, primeiro a ser atendido é conhecida como *FCFS* ou *FIFO*.

Chegadas: taxa λ

A taxa de chegada, representada por λ, informa quantas solicitações entram no sistema em média por unidade de tempo.

Se chegam quatro pedidos por minuto, o intervalo médio entre chegadas é um quarto de minuto, ou quinze segundos.

Uma média não significa regularidade: pedidos podem chegar próximos uns dos outros e produzir filas mesmo sem aumento da média.

Exemplo: λ = 4 solicitações/minuto corresponde a um intervalo médio de 15 segundos.

PARÂMETROS

λ = 4/min

chegadas médias

1/λ = 0,25 min

intervalo médio

0,25 min = 15 s

conversão

Atendimento: taxa μ

A taxa de serviço, representada por μ, informa quantas solicitações um servidor consegue processar em média por unidade de tempo.

Se um servidor conclui seis pedidos por minuto, seu tempo médio de serviço é um sexto de minuto, aproximadamente dez segundos.

Não confunda tempo de processamento com tempo de resposta: uma solicitação pode passar mais tempo aguardando do que sendo atendida.

Exemplo: μ = 6 solicitações/minuto significa serviço médio de aproximadamente 10 segundos.

PARÂMETROS

μ = 6/min

atendimentos médios

1/μ = 0,167 min

serviço médio

≈ 10 segundos

conversão

Métricas que orientam decisões

A utilização ρ representa a fração do tempo em que o servidor está ocupado, enquanto W mede o tempo médio total.

Wq corresponde somente à espera na fila; L conta solicitações no sistema e Lq considera apenas aquelas aguardando atendimento.

Essas métricas respondem perguntas diferentes e precisam ser acompanhadas de unidades, período de observação e contexto do experimento.

Convenção: W e Wq em minutos; L e Lq em solicitações; ρ é uma proporção.

MÉTRICAS

ρ, W, Wq

ocupação e tempos

L, Lq

quantidade média

W = Wq + 1/μ

tempo total

A Lei de Little

A Lei de Little relaciona a quantidade média de solicitações presentes no sistema, a vazão média e o tempo médio de permanência.

Em condições estáveis e com grandezas medidas de forma coerente, a relação é L = λ × W.

Para a fila isoladamente, também podemos escrever Lq = λ × Wq, usando a taxa efetiva de entradas correspondente.

Se entram 4 pedidos/minuto e cada pedido permanece 0,5 minuto, L = 2 pedidos.

RELAÇÕES

L = λ × W

sistema completo

Lq = λ × Wq

apenas a fila

4 × 0,5 = 2

exemplo

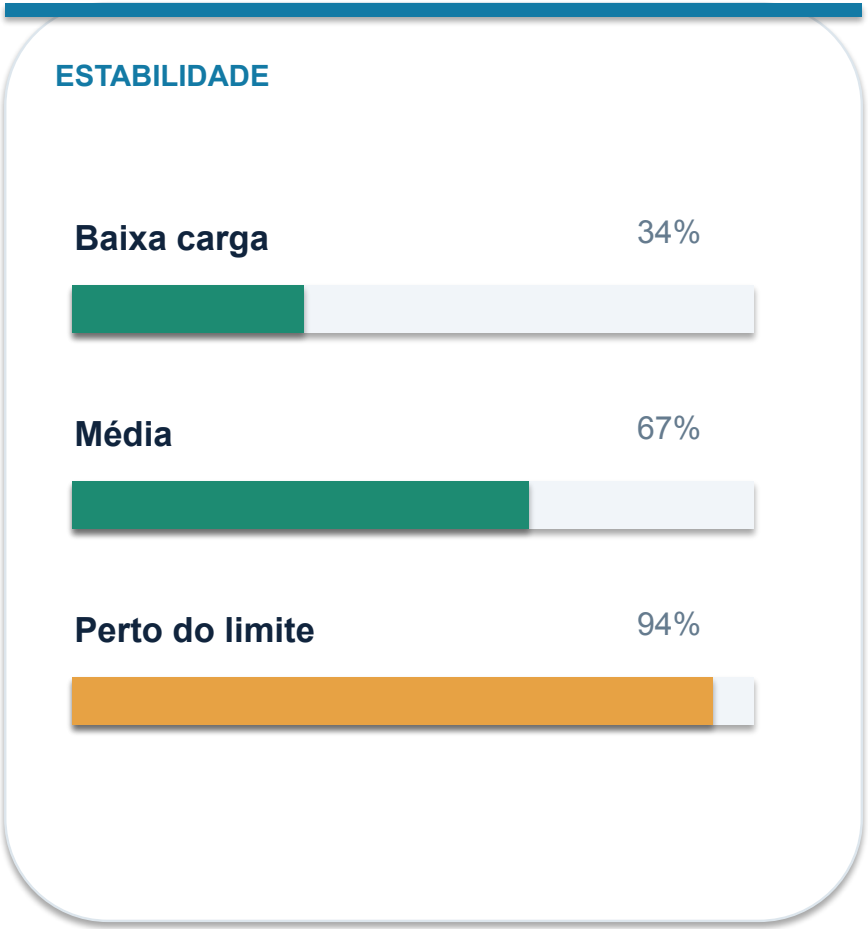
Utilização e estabilidade

Em um sistema com um servidor, a utilização teórica é ρ = λ/μ quando a carga é estável.

Se a chegada média alcança ou ultrapassa a capacidade de atendimento, uma fila ilimitada tende a crescer sem limite.

Mesmo abaixo desse limite, tempos de espera podem aumentar rapidamente quando a utilização se aproxima de cem por cento.

Para uma fila *M/M/1* estável, exigimos λ menor que μ, ou equivalentemente ρ menor que 1.



O modelo *M/M/1*

O nome *M/M/1* resume três hipóteses: chegadas de Poisson, tempos de serviço exponenciais e apenas um servidor.

O modelo básico também considera atendimento na ordem de chegada e capacidade ilimitada para as solicitações que esperam.

Por ser simples, ele ajuda a compreender a formação de filas antes de avançarmos para modelos mais próximos da realidade.

M indica a propriedade de ausência de memória; 1 indica um único servidor.

TEORIA DE FILAS

Fórmulas essenciais do *M/M/1*

Para λ menor que μ, o tempo médio total é W = 1/(μ − λ), incluindo espera e atendimento.

A espera média na fila é Wq = λ/[μ(μ − λ)], e a utilização é ρ = λ/μ.

Pela Lei de Little, obtemos L = λW e Lq = λWq, sempre mantendo unidades compatíveis.

TEORIA DE FILAS

ρ = λ/μ

utilização

W = 1/(μ − λ)

tempo total

Wq = λ/[μ(μ−λ)]

espera

As fórmulas apresentadas valem para o *M/M/1* em regime estacionário; não são universais.

Exemplo guiado: servidor de matrículas

Considere quatro solicitações chegando por minuto e um servidor capaz de atender seis solicitações por minuto.

Aplicando as fórmulas, obtemos utilização de 66,7%, resposta média de 30 segundos e espera média de 20 segundos.

Em média há duas solicitações no sistema, com aproximadamente 1,33 na fila; números fracionários representam médias.

Converta 0,5 minuto em 30 segundos e 0,333 minuto em 20 segundos.

EXEMPLO

ρ = 66,7%

ocupação

W = 30 s

resposta total

Wq = 20 s

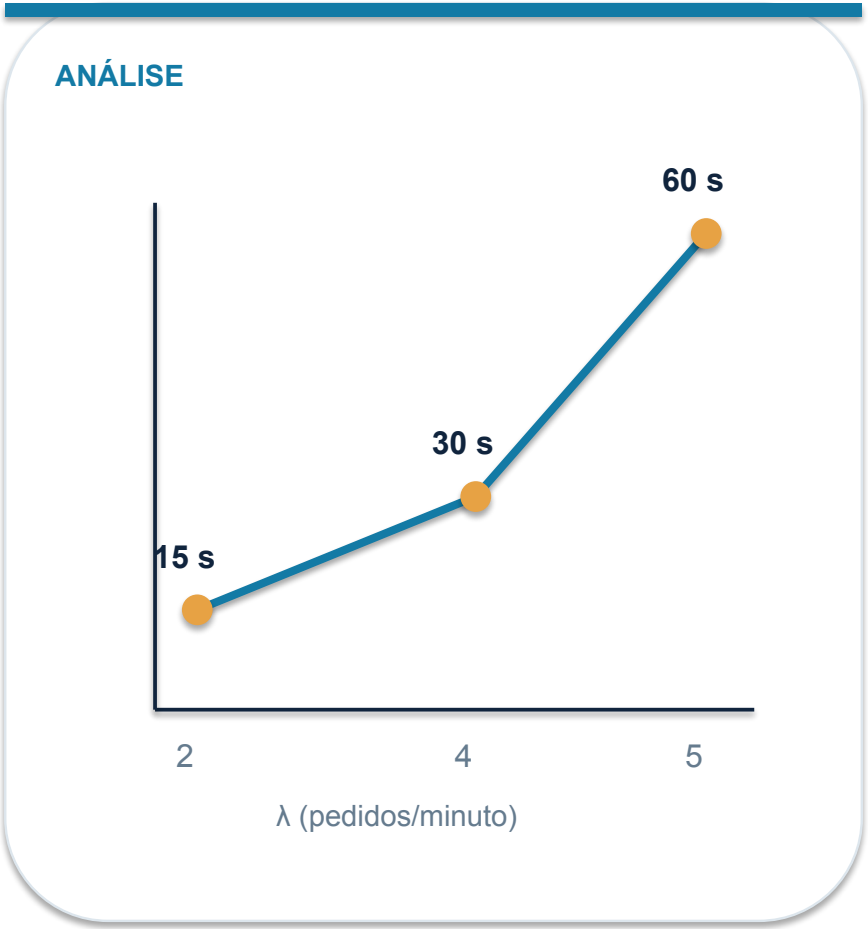
espera

O risco de operar perto do limite

Mantendo a capacidade em seis pedidos por minuto, aumentar a chegada de dois para cinco pedidos eleva bastante a utilização.

O tempo médio teórico no sistema passa de quinze segundos para sessenta segundos, embora a demanda não tenha triplicado.

Esse comportamento não linear explica por que pequenos aumentos de carga podem causar grandes atrasos perto da saturação.



Cenários *M/M/1*: λ = 2, 4 e 5/min; μ = 6/min; W = 15, 30 e 60 segundos.

Quando o modelo simplifica demais

Aplicações reais podem usar vários servidores, ter filas limitadas, executar prioridades e receber picos de demanda previsíveis.

Os tempos de processamento também podem depender do tipo de requisição, do banco de dados e de recursos compartilhados.

Quando essas características importam, uma simulação mais detalhada pode representar melhor o comportamento do sistema que uma fórmula simples.

Toda conclusão precisa informar o que foi incluído no modelo e o que ficou de fora.

LIMITAÇÕES

M/M/1	REAL
1 servidor fila ilimitada taxas fixas	vários serviços picos de carga prioridades

A hipótese deve combinar com a pergunta.

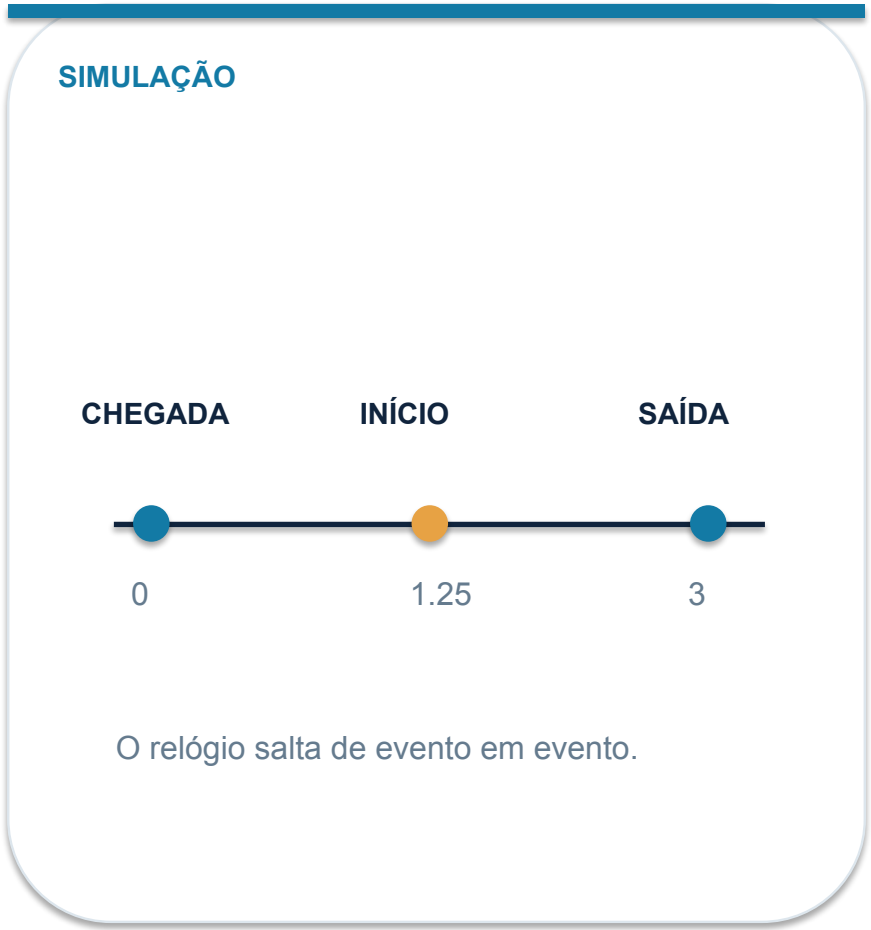
O que é simulação de eventos discretos?

Uma simulação de eventos discretos acompanha mudanças do sistema apenas nos instantes em que acontecimentos relevantes ocorrem.

No exemplo, os eventos são chegada de solicitação, início de atendimento e conclusão do processamento, sem calcular cada milissegundo.

O relógio simulado avança diretamente para o próximo evento, tornando possível estudar muitos pedidos com baixo custo computacional.

Evento é uma ocorrência que altera o estado; o relógio é virtual, não o tempo real de execução.



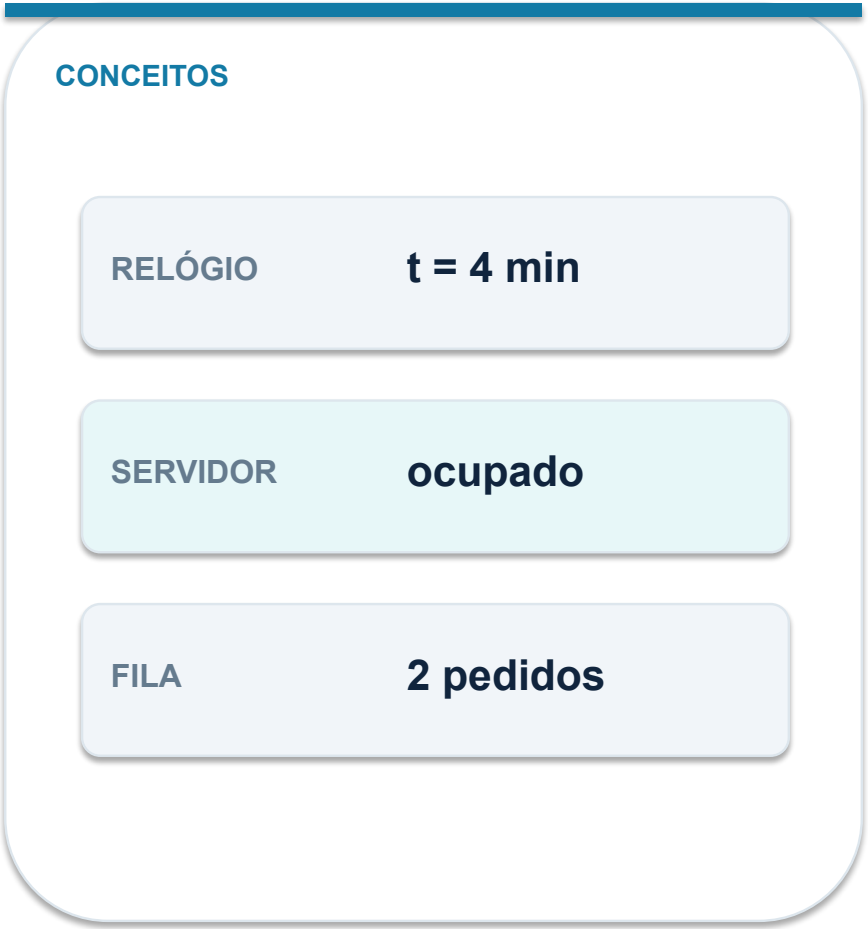
Relógio, estado e eventos

O relógio virtual registra o instante atual, enquanto o estado resume informações como servidor ocupado e tamanho da fila.

Eventos alteram o estado: uma chegada pode ocupar o servidor ou aumentar a espera; uma saída pode liberar capacidade.

As métricas são acumuladas durante a execução, permitindo calcular tempos médios e comparar resultados com o modelo matemático.

Exemplo de estado: relógio = 4 min; servidor ocupado; duas solicitações aguardando.



Agenda de eventos futuros

A agenda armazena eventos ordenados por instante, garantindo que o simulador processe primeiro aquilo que acontece mais cedo.

Uma chegada pode programar a próxima chegada, enquanto o início de atendimento programa o instante de saída correspondente.

No *Python*, uma fila de prioridade permite retirar rapidamente o evento com menor tempo, sem ordenar toda a lista repetidamente.

No laboratório, *heapq* organiza tuplas contendo instante, ordem, tipo de evento e identificador.

CONCEITOS

t = 1,0	CHEGADA
t = 3,0	SAÍDA
t = 4,0	CHEGADA

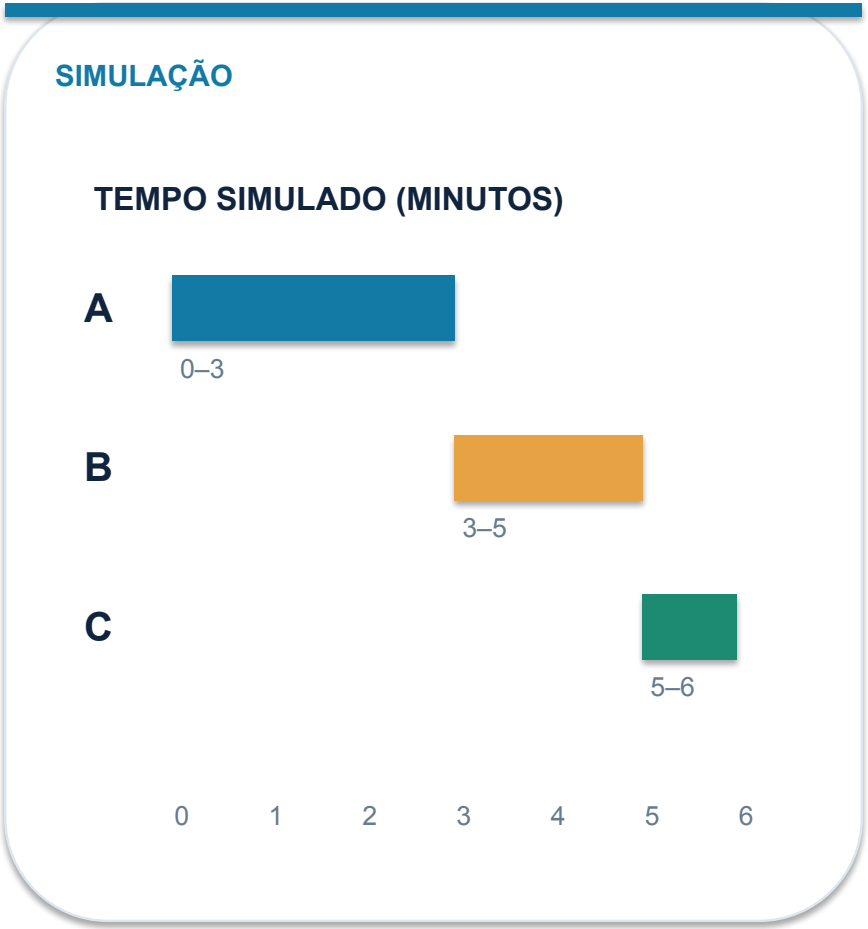
Sempre executar o menor instante primeiro.

Exemplo manual com três solicitações

A solicitação A chega no instante zero e ocupa o servidor durante três minutos, encerrando o atendimento no instante três.

B chega no minuto um e espera até três; C chega no minuto quatro e espera até cinco.

Os tempos de espera são zero, dois e um minuto, respectivamente, produzindo espera média de um minuto nesse exemplo finito.



A: 0–3; B: 3–5; C: 5–6. Espera média = (0 + 2 + 1)/3 = 1 minuto.

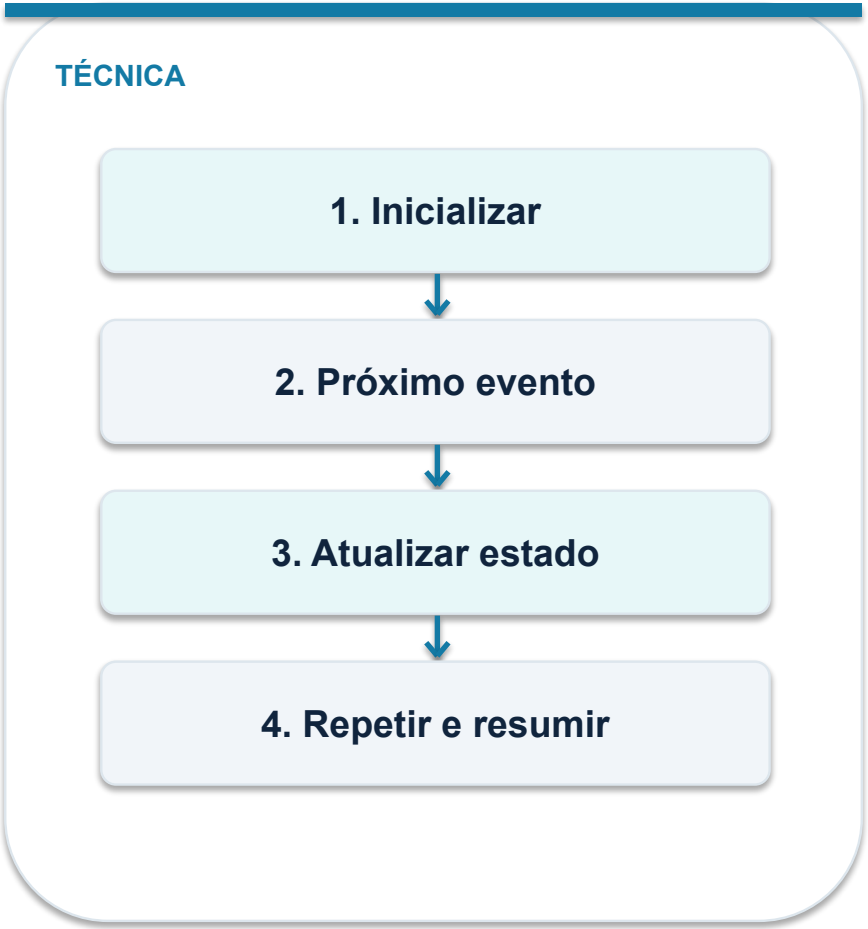
Algoritmo básico da simulação

Inicialmente definimos parâmetros, criamos o estado vazio e agendamos a primeira chegada ao sistema que será estudado.

Em cada passo, retiramos o próximo evento, avançamos o relógio, atualizamos o estado e agendamos novos eventos quando necessário.

A execução termina quando o critério escolhido é atingido; depois calculamos métricas e verificamos se os resultados fazem sentido.

Fluxo: inicializar → retirar evento → atualizar estado → agendar → repetir → resumir.



Modelos determinísticos e aleatórios

No modelo determinístico, as mesmas entradas produzem sempre os mesmos instantes e resultados, sem sorteio de valores.

No modelo estocástico, variáveis aleatórias representam incertezas, como intervalos irregulares entre chegadas e durações de atendimento.

A escolha depende da pergunta e dos dados disponíveis; introduzir aleatoriedade sem justificativa não torna o modelo automaticamente melhor.

Estocástico significa que pelo menos uma variável do modelo é representada probabilisticamente.

TÉCNICA

FIXO	ALEATÓRIO
15 s	3 s
15 s	24 s
15 s	18 s

Mesma média, diferentes padrões.

Variabilidade das chegadas

Em muitos modelos de filas, os intervalos entre chegadas são representados por uma distribuição exponencial, caracterizada por uma média.

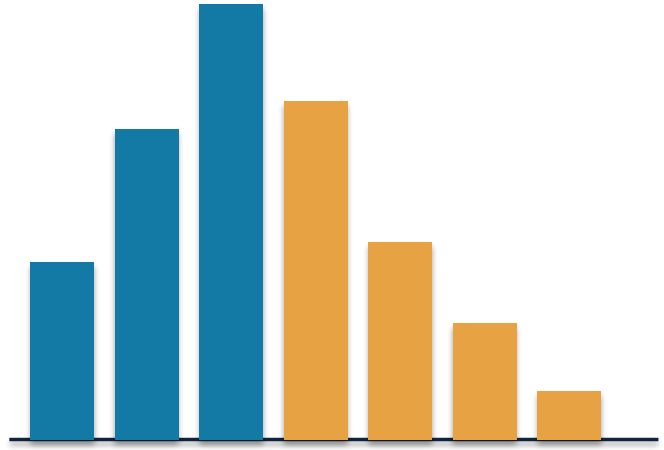
Isso permite intervalos curtos ou longos, embora a taxa média permaneça a mesma durante o período observado.

Uma semente pseudoaleatória permite repetir exatamente a sequência gerada, facilitando depuração e comparação entre experimentos.

Exponencial não significa crescimento exponencial da demanda; é o nome de uma distribuição de probabilidades.

ESTATÍSTICA

Intervalos curtos são frequentes;



intervalos longos também ocorrem.

Ferramentas gratuitas para a prática

O *Google Colab* executa *Python* no navegador e permite trabalhar com um caderno interativo sem instalar um ambiente local.

O *Python* oferece recursos padrão para eventos, filas e sorteios; a biblioteca *SimPy* facilita modelos mais elaborados com processos e recursos.

Para esta aula, o laboratório principal usa somente *Python* padrão, deixando *SimPy* como alternativa gratuita para aprofundamento posterior.

Fontes: *colab*.research.google.com e *simpy*.readthedocs.io (documentação oficial).



Laboratório: preparar o ambiente

Abra o *Google Colab*, crie um novo caderno e confirme que a linguagem selecionada para execução é *Python*.

Em seguida, importe o arquivo de laboratório fornecido ou copie as células do roteiro para o novo caderno.

Execute primeiro a célula de parâmetros e confira os resultados teóricos antes de iniciar a simulação completa.

PASSO A PASSO

1 Abrir *Colab*

2 Carregar caderno

3 Executar cálculos

4 Conferir valores

Passos: acessar *Colab* → abrir .ipynb → executar célula → conferir λ, μ, ρ, W e Wq.

Laboratório: definir parâmetros

No início do código, escolha taxa de chegada, taxa de serviço, quantidade de solicitações e semente do gerador aleatório.

Use λ igual a quatro e μ igual a seis, mantendo as unidades em solicitações por minuto durante todo o experimento.

Comece com cem mil solicitações e descarte as dez mil primeiras observações das médias para reduzir o efeito inicial.

Parâmetros da execução principal: λ = 4/min, μ = 6/min, total = 100.000, aquecimento = 10.000.

PASSO A PASSO

```
λ = 4 / minuto
μ = 6 / minuto
total = 100000
aquecimento = 10000
semente = 2026
```

Laboratório: agendar eventos

A função de agendamento registra o instante, o tipo e o identificador de cada evento em uma estrutura ordenada.

Quando uma chegada é processada, o programa registra a solicitação e sorteia o intervalo até a próxima chegada.

Quando o servidor inicia um atendimento, sorteia a duração do serviço e agenda a saída correspondente no relógio virtual.

Bibliotecas: *heapq* organiza a agenda; *random.expovariate* gera intervalos exponenciais.

PASSO A PASSO

```
heappush(agenda, evento)

proximo = heappop(agenda)

intervalo = rng.expovariate(λ)
```

PASSO A PASSO

Laboratório: processar a fila

Se uma solicitação chega com o servidor livre, o atendimento começa imediatamente e uma saída futura é agendada.

Caso o servidor esteja ocupado, o pedido entra na fila e aguarda até que a saída anterior libere o recurso.

Na saída, o programa registra o tempo total e pode iniciar o próximo pedido, preservando a ordem de chegada.

PASSO A PASSO

```
if servidor_ocupado:
    fila.append(pedido)
else:
    iniciar_servico()

# na saída: fila.popleft()
```

A fila de pedidos usa *deque*; a agenda de eventos usa *heapq*. São estruturas diferentes.

PASSO A PASSO

Laboratório: executar e medir

Execute a função de simulação e observe os tempos médios calculados a partir das solicitações que foram concluídas.

Compare a média simulada com a previsão matemática e registre a diferença sem alterar as unidades utilizadas.

Por fim, execute outros cenários de chegada mantendo a capacidade constante e observe a mudança na utilização e na espera.

A execução de referência produz W simulado próximo de 0,511 minuto, contra W teórico de 0,500 minuto.

PASSO A PASSO

```
r = simular_fila(4, 6)

print(r["W_teorico"])
print(r["W_simulado"])

# comparar cenários
```

Teoria versus simulação

Os valores calculados por fórmulas descrevem médias de longo prazo sob as hipóteses matemáticas do modelo *M/M/1*.

Os valores simulados resultam de uma quantidade finita de eventos e podem variar de uma execução para outra.

No cenário principal, a previsão de 0,500 minuto ficou próxima da média simulada de aproximadamente 0,511 minuto.

Aproximação não é igualdade: reporte sempre parâmetros, semente, tamanho da amostra e unidades.

RESULTADOS

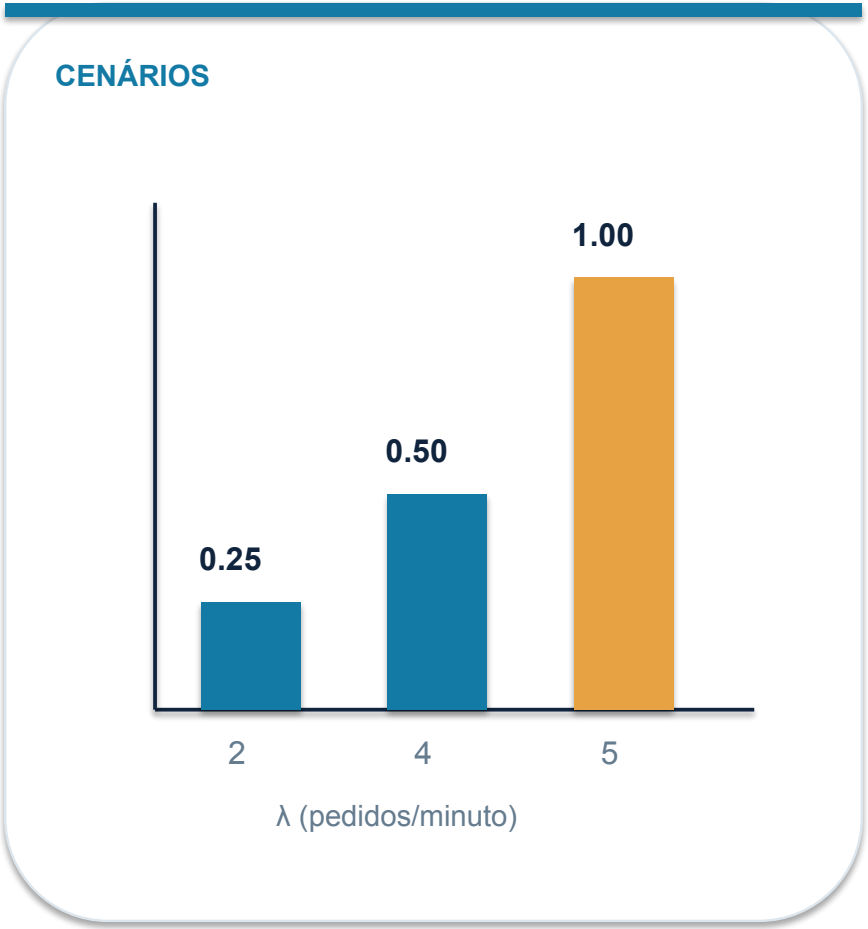
	TEORIA	SIMULAÇÃO
W total	**0,500**	**0,511**
W fila	**0,333**	**0,345**
ρ	**66,7%**	**66,8%**

Experimento: aumentar a demanda

Mantenha a taxa de atendimento em seis pedidos por minuto e teste chegadas médias de dois, quatro e cinco pedidos.

Os tempos teóricos passam de 0,25 para 0,50 e depois 1,00 minuto, mostrando aumento não proporcional.

Peça aos alunos que comparem a curva teórica com a simulação e expliquem por que a espera cresce perto do limite.



Com μ = 6/min: λ = 2, 4 e 5/min resultam em ρ = 33%, 67% e 83%.

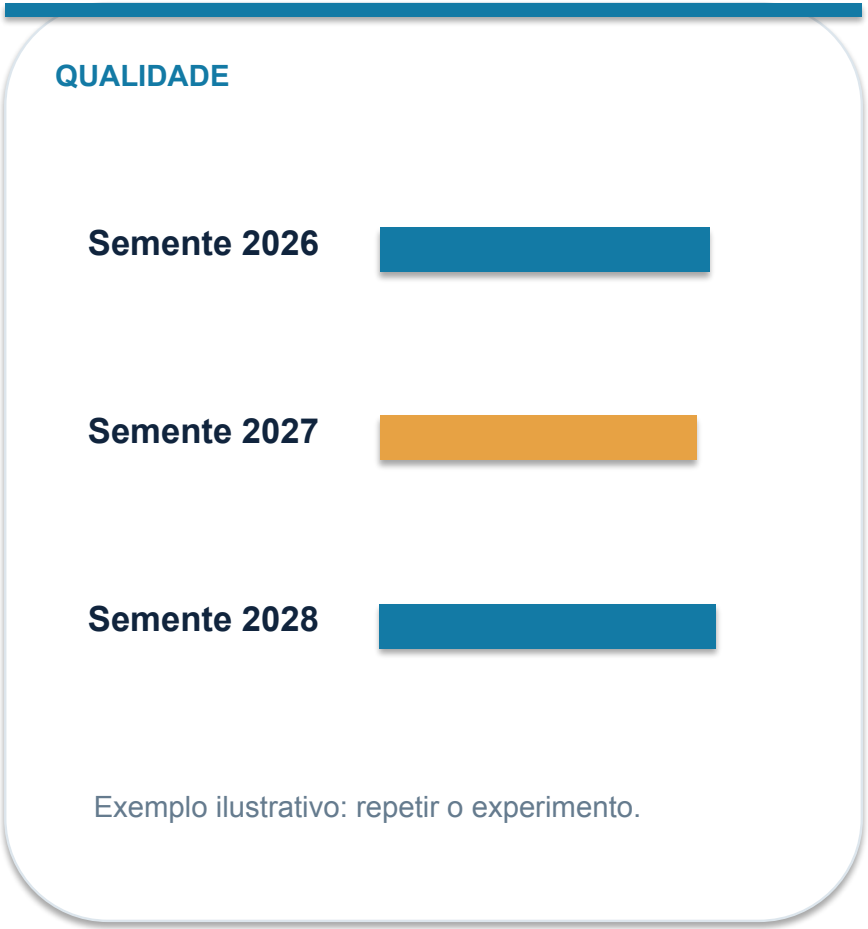
Repetição e semente aleatória

Uma única execução pode produzir uma média influenciada por flutuações aleatórias, principalmente quando a amostra é pequena.

Repetir a simulação com sementes diferentes permite observar a dispersão e avaliar a estabilidade das conclusões obtidas.

Registre sempre o total de solicitações, o aquecimento, as taxas e a semente para que outra pessoa reproduza o experimento.

Experimento sugerido: repetir com sementes 2026, 2027 e 2028 e comparar a média de W.



Verificação e validação do modelo

Verificação pergunta se o programa implementa corretamente as regras planejadas, incluindo ordem dos eventos e cálculo das métricas.

Validação pergunta se as hipóteses e o comportamento do modelo representam suficientemente o sistema real para o objetivo.

Comparar resultados com fórmulas conhecidas ajuda na verificação, mas dados observados e conhecimento do domínio são essenciais à validação.



Verificação: construí corretamente? Validação: construí o modelo adequado para o problema?

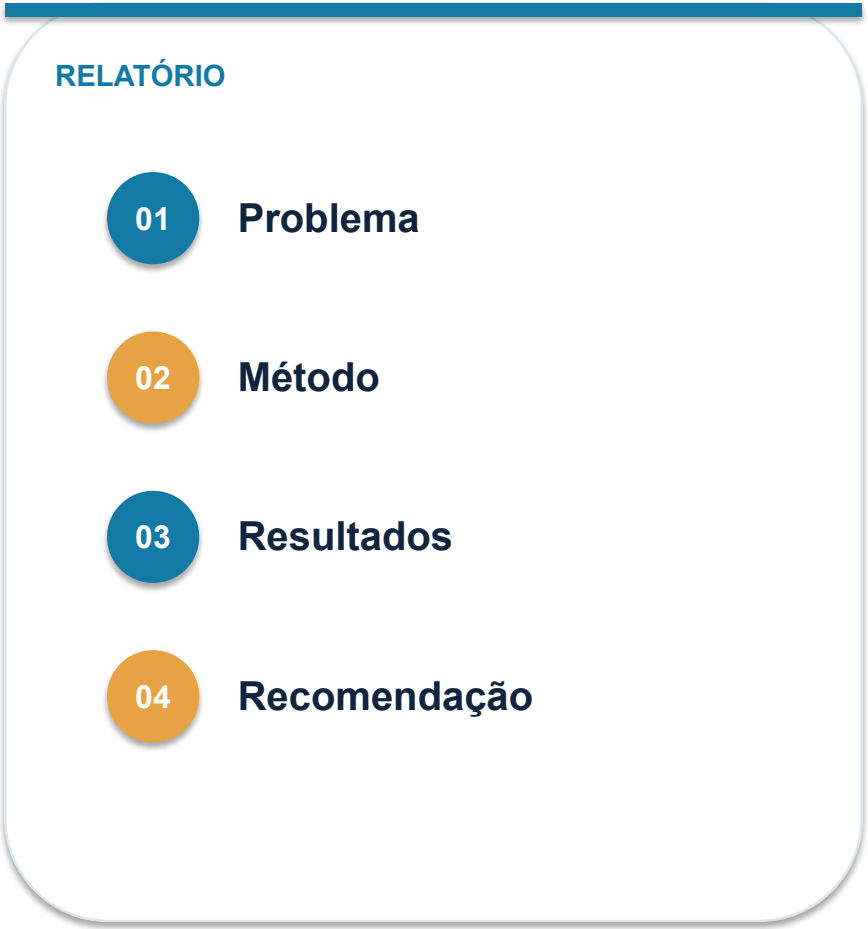
Como comunicar resultados

Um relatório técnico deve declarar o problema, as hipóteses, as variáveis, o método e as condições de execução do experimento.

Apresente os indicadores em tabela ou gráfico com unidades e identifique claramente quais números são teóricos e quais foram simulados.

Finalize com interpretação, limitações e uma recomendação que possa ser testada, evitando conclusões baseadas apenas em uma execução.

Estrutura mínima: objetivo → cenário → método → resultados → análise → limites → recomendação.



Exercício resolvido: situação

Um serviço recebe em média oito solicitações por segundo e consegue concluir dez solicitações por segundo com um único servidor.

Admita as hipóteses do *M/M/1*, atendimento por ordem de chegada e fila ilimitada, com taxas constantes durante o período.

Calcule a utilização, o tempo médio total, a espera média na fila e as quantidades médias de solicitações no sistema.

Dados: λ = 8/s; μ = 10/s. Antes de calcular, verifique se λ é menor que μ.

EXERCÍCIO RESOLVIDO

λ	**8 / segundo**
μ	**10 / segundo**
Calcular	**ρ, W, Wq, L, Lq**

Exercício resolvido: solução

A utilização é ρ = 8/10 = 0,8, portanto o servidor fica ocupado aproximadamente oitenta por cento do tempo.

O tempo médio total é W = 1/(10 − 8) = 0,5 segundo, e a espera média é Wq = 0,4 segundo.

Pela Lei de Little, L = 8 × 0,5 = 4 solicitações e Lq = 8 × 0,4 = 3,2 solicitações.

Conferência: W − Wq = 0,1 segundo, exatamente o tempo médio de serviço 1/μ.

EXERCÍCIO RESOLVIDO

ρ	**80%**
W / Wq	**0,5 s / 0,4 s**
L / Lq	**4 / 3,2**

Exercício avaliativo

Considere uma aplicação com chegadas médias de três solicitações por minuto e atendimento de cinco solicitações por minuto.

Calcule ρ, W, Wq, L e Lq, explique as unidades e execute o laboratório usando exatamente esses parâmetros.

Depois aumente λ para 4,5 por minuto, mantendo μ constante, e interprete as mudanças observadas no desempenho.

Entrega: cálculos, tabela de resultados, gráfico ou captura e explicação de duas limitações do modelo.

AVALIAÇÃO

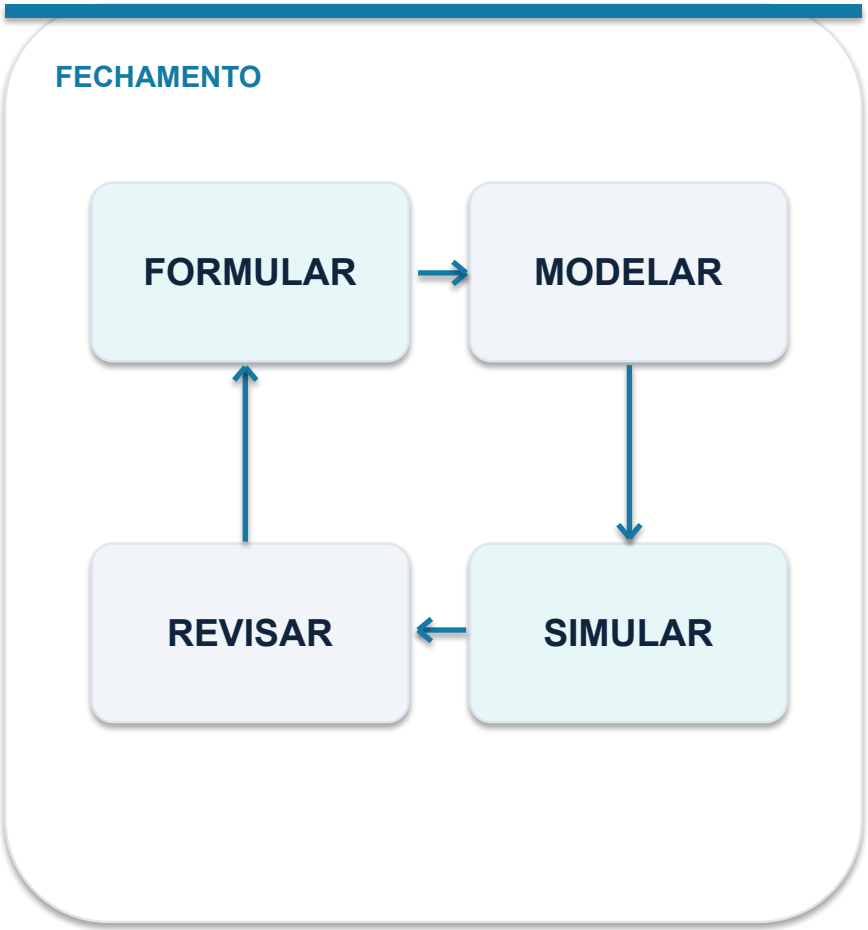
Cenário A	**λ=3; μ=5**
Cenário B	**λ=4,5; μ=5**
Entrega	**cálculo + análise**

Do modelo à decisão técnica

Começamos identificando chegadas, capacidade e indicadores; depois utilizamos equações para estimar o comportamento médio de uma fila.

A simulação permitiu representar eventos e comparar cenários sem modificar um sistema real ou assumir que todos os pedidos são iguais.

Uma avaliação consistente combina hipótese explícita, execução reprodutível, interpretação crítica e recomendação fundamentada nos resultados.



Ideia central: formular → modelar → simular → comparar → revisar.

Referências e materiais de apoio

JOHNSON, T. M. S. M.; COUTINHO, M. M. Avaliação de desempenho de sistemas computacionais. Rio de Janeiro: LTC, 2011.

SIMPY. Documentação oficial de processos, eventos e recursos. Disponível em: *simpy*.readthedocs.io.

GOOGLE. Colaboratory. Disponível em: *colab*.research.google.com. Complemento: material acadêmico de teoria de filas da University of Aizu.

Referências completas, links clicáveis e roteiro prático encontram-se nas anotações deste slide.

REFERÊNCIAS

LIVRO	Johnson e Coutinho
SIMPY	Documentação oficial
COLAB	Ambiente gratuito